**Proyecto 2 - Frameworks y herramientas para big data: Despliegue de arquitectura Lakehouse y pipeline de ingesta y cargue de datos.**

**Profesor: Oscar Andrés Jiménez Villanueva.**

**Objetivo:**

Diseñar, desplegar y ejecutar una arquitectura **Lakehouse** utilizando MinIO como object storage, Apache Iceberg como formato de tablas, Apache Spark para procesamiento de datos, Nessie como catálogo, Airflow para orquestación de pipelines, DLT para ingesta, y Dremio/Trino como motores SQL.

El proyecto debe implementar la **arquitectura Medallion (Bronze → Silver → Gold)** con lógica de ingesta, transformación, calidad de datos y agregación.

**Infraestructura Requerida:**

- MinIO (object storage)
- Nessie (catálogo de metadatos)
- Apache Iceberg (table format)
- Apache Spark con PySpark (procesamiento)
- Apache Airflow (orquestación)
- Jupyter Notebook (ejecución manual alterna)
- Dremio y Trino (consulta SQL)

**Arquitectura Medallion:**

- **Bronze**
    - Almacenamiento en **Parquet**.
    - Sobrescritura (override) permitida.
    - Contenido: datos crudos diarios (anuales) de la fuente seleccionada.
    - Cargar más de un año.
- **Silver**
    - Tablas en formato **Iceberg**.
    - Escritura con **merge** (no override), para manejar duplicados y cambios históricos.

    - Contenido: tablas curadas y normalizadas e históricas
    - Cargar más de un año, se puede limitar la cantidad de registros.
    - Deben tener columna de fecha de cargue.
- **Gold**
    - Tablas en formato **Iceberg**.
    - Escritura con **merge**, con reglas de negocio y agregaciones.
    - Deben tener columna de fecha de cargue.
    - Contenido: métricas, KPIs y tablas analíticas.

**Orquestación (Airflow):**

- DAG con al menos 3 tareas:
    1. Ingesta Bronze (usando DLT).
    2. Transformación Silver (PySpark + Iceberg).
    3. Agregación Gold (PySpark + Iceberg).
- El DAG debe poder ejecutarse completo con un solo “Play” en Airflow.

**Ejecución manual (Jupyter):**

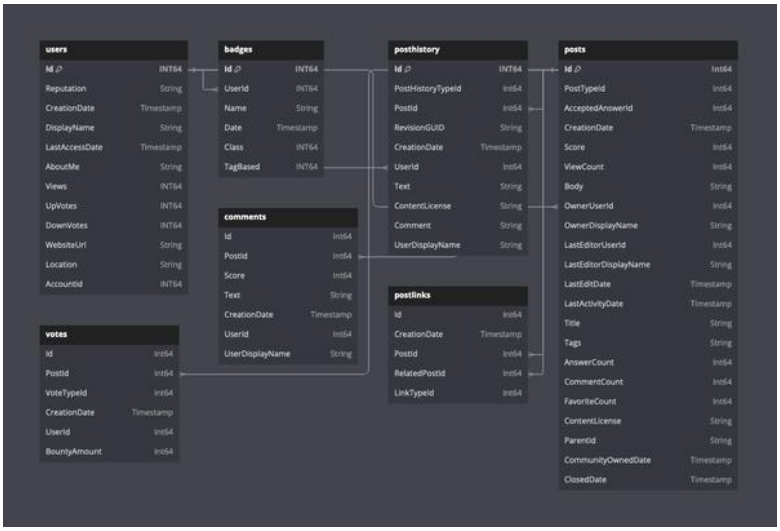
- Tres notebooks/scripts independientes:
    - bronze_ingest.ipynb
    - silver_transform.ipynb
    - gold_agg.ipynb
- Cada script debe poder ejecutarse manualmente en caso de fallo en Airflow.

**Entrega en Docker:**

- Todos los servicios deben estar contenidos en un Docker Compose.
- Incluir un archivo **README.md** con instrucciones de:
    - Despliegue de los contenedores.
    - Comandos necesarios.
    - Acceso a Minio, Airflow, Jupyter, Dremio ,Trino, etc.

**Dataset:**

- Dataset base recomendado: **StackOverflow dataset (ClickHouse)** https://clickhouse.com/docs/getting-started/example-datasets/stackoverflow
    - Tablas incluidas: Posts, Users, Votes, Comments, Badges, PostLinks, PostHistory.




**Ejemplos de Tablas en Gold (1):**

Algunas tablas esperadas o de ejemplo:

- **post_counts_by_user**: número de preguntas y respuestas publicadas por usuario.
- **vote_stats_per_post**: votos positivos/negativos por post.
- **top_tags** → ranking de etiquetas con mayor número de preguntas.
- **user_engagement** : interacciones de cada usuario (posts, comentarios, votos, badges).
- **badges_summary** : número y tipo de insignias obtenidas por usuario.

**Criterios de Calificación:**

**1. Entregables – 20%**

- docker-compose.yml para el despliegue.
- Archivo **README.md** con instrucciones de uso.

- DAG de Airflow con las tres tareas (Bronze, Silver, Gold).
- Notebooks de respaldo (bronze_ingest.ipynb, silver_transform.ipynb, gold_agg.ipynb).
- Consultas a ejecutar desde silver (replicar tablas gold).
- Diagrama de la arquitectura implementada.

**2. Infraestructura – 30%**

- Contenedores desplegados correctamente.
- Todos los servicios ejecutándose en Docker (MinIO, Airflow, Spark, Nessie, Dremio, Trino, Jupyter, etc).

**3. Pipeline – 30% (10% cada etapa)**

- **Bronze:** ejecución correcta, almacenamiento Parquet con override.
- **Silver:** ejecución correcta con escritura en Iceberg usando **merge**.
- **Gold:** ejecución correcta con escritura en Iceberg usando **merge**, generando agregaciones y métricas.

⚠️ En caso de fallo de Airflow, se evaluará la ejecución manual de los notebooks.

**4. Consumo y Consulta – 20%**

- Tablas disponibles y consultables desde ambos motores:
    - 10% → Trino - Tablas de silver. Los registros de las tablas de gold deben replicarse por medio de consultas a las tablas de silver.
    - 10% → Dremio - Tablas de gold.

**Aclaración sobre el alcance del pipeline:**

Para simplificar la implementación, **no es necesario cargar todos los datasets a través del pipeline**. La estrategia recomendada es la siguiente:

En la capa **Bronze**, deben cargar dos años de datos por dataset. Sin embargo, **solo un año de un único dataset debe ejecutarse por el pipeline de Airflow**. El resto se carga manualmente en las rutas de Bronze. Por ejemplo, para post pueden subir manualmente los archivos post_2020.parquet y post_2021.parquet. Para users,

suben users_2020 de forma manual y únicamente users_2021 es el que se ejecuta a través del pipeline durante la clase.

En la capa **Silver**, la tabla histórica de post (post_hist) puede construirse mediante un script manual que lea los dos Parquet de Bronze y los consolide en una sola tabla. La tabla users_hist, en cambio, es la que se procesa a través del pipeline en clase.

Finalmente, en la capa **Gold**, la tabla de métricas se genera dentro del pipeline a partir de **las dos tablas históricas de Silver** (post_hist y users_hist). Es decir, cuando ejecuten el DAG en Airflow, el flujo completo será: ingesta de users_2021 en Bronze → consolidación de users_hist en Silver → generación de métricas en Gold, donde esta última tabla cruza y agrega información de ambas tablas históricas.

